





Z kolei DataFrame to wysokopoziomowa struktura danych, przypominająca tabelę w relacyjnej bazie danych lub arkusz kalkulacyjny. W przeciwieństwie do RDD, DataFrame posiada sztywno zdefiniowany schemat (nazwy kolumn wraz z ich typami danych). Dzięki tej strukturyzacji Spark może zastosować zaawansowany optymalizator zapytań Catalyst, który przed uruchomieniem obliczeń analizuje kod i buduje najbardziej efektywny plan jego wykonania. DataFrame automatycznie optymalizuje operacje sieciowe oraz pamięciowe, drastycznie zwiększając wydajność i oferując programiście intuicyjne API oparte na operacjach znanych z języka SQL.